# 实 验 报 告

学	号	20020006107	姓	名	王义钧	专业班级		通信工程			
课程	2名称	自然语			<u> </u>	学期	2022 年 春 季学期				
任课教师 仲国强			完成日期 2022/5			/27 上机课时间			2022/5/26		
实	验名	自 然 语 言 处 实 验	· · · · · · · · · · · · · · · · · ·								

## 一、 实验目的

按照处理文本的粒度不同,情感分析可分为词语级、短语级、句子级、段落级以及篇章级等几个研究层次。这里以"段落级"为例,输入为一个段落,输出为影评是正面还是负面的信息。 本次实验,以 IMDB 影评情感分类体验 MindSpore 在自然语言处理上的应用。

# 二、 实验内容:

- 1. 准备环节。
- 2. 加载数据集,进行数据处理。
- 3. 定义网络。
- 4. 定义优化器和损失函数。
- 5. 使用网络训练数据, 生成模型。
- 6. 得到模型之后,使用验证数据集,查看模型精度情况。

# 三、 实验过程:

1、预安装 Annaconda 和 mindspore

安装完成 Annaconda 并配置好环境变量。

进入 cmd 验证 conda 环境是否配置好。

验证过程遇到输入 conda activate 命令后无响应的错误:

CommandNotFoundError: Your shell has not been properly configured to use 'conda activate'.

To initialize your shell, run
\$ conda init <SHELL\_NAME>

Currently supported shells are:

- bash
- fish
- tcsh
- xonsh
- zsh
- powershell

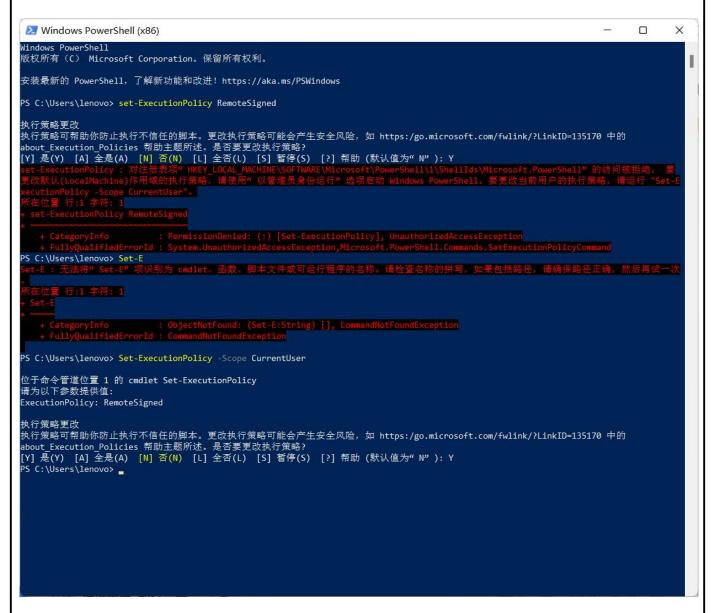
See 'conda init --help' for more information and options.

IMPORTANT: You may need to close and restart your shell after running 'conda init'.

#### 解决方法:

- (1) 通过 Win10 开始菜单进入 Windows PowerShell (管理员)
- (2) 输入命令 set-ExecutionPolicy RemoteSigned,如果无其他提示的红色错误后,输入 Y 直接解决。
  - (3) 因为我的电脑受到管理员账户的控制,权限有限,我根据输入步骤2中的红色提示

信息后,输入以下命令行 Set-ExecutionPolicy-Scope CurrentUser ,然后在 ExecutionPolicy: 参数值这个位置输入 RemoteSigned 并最终也解决了问题。



## 结果:

C:\Users\王义钧>conda --v conda 4.12.0

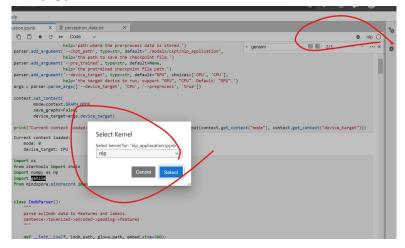
2、配置好 kernels 并启动 jupyter lab

(Wangyijun) PS D:\NLP\实验三> python -m ipykernel install --user --name Wangyijun --display-name Wangyijun Installed kernelspec Wangyijun in C:\Users\lenovo\AppData\Roaming\jupyter\kernels\wangyijun

在下面运行数据集训练代码时遇到错误,所以这里需要重新配置环境,并更换 jupyter 的核。

Pip env list 查看可用的核及其地址 并将不需要的核删去。

## 更改 jupyter lab 当前环境下的核。



#### 3、测试运行训练集代码

①配置训练相关参数: 经过测试,一般没有问题:

from mindspore.mindrecord import FileWriter

```
from mindspore import context
                from easydict import EasyDict as edict
                # LSTM CONFIG
               # ISM CONFIG

Ism_cfg = edict({

    'num_classes': 2,

    'learning_rate': 0.1,

    'momentum': 0.9,

    'num_epochs': 10,

    'batch_size': 64,

    'amhad_size': 300
                           'embed_size': 300,
'num_hiddens': 100,
                           'num_layers': 2,
'bidirectional': True,
                            'save_checkpoint_steps': 390,
'keep_checkpoint_max': 10
               })
              parser = argparse.ArgumentParser(description='MindSpore LSTM Example')
parser.add_argument('--preprocess', type=str, default='false', choices=['true', 'false'], help='whether to preprocess date parser.add_argument('--aclimdb_path', type=str, default="./datasets/aclImdb", help='path where the dataset is stored.')
parser.add_argument('--glove_path', type=str, default="./datasets/glove", help='path where the GloVe is stored.')
parser.add_argument('--preprocess_path', type=str, default="./preprocess", help='path where the pre-process data is stored parser.add_argument('--pre_trained', type=str, default="./models/ckpt/nlp_application", help='the path to save the checkpt parser.add_argument('--pre_trained', type=str, default=None, help='the pretrained checkpoint file path.')
parser.add_argument('--device_target', type=str, default="GPU", choices=['GPU', 'CPU'], help='the target device to run, args = parser.parse_args(['--device_target', 'CPU', '--preprocess', 'true'])
               context.set context(
                           save_graphs=False,
                           device_target=args.device_target)
               print("Current context loaded:\n mode: {}\n device_target: {}".format(context.get_context("mode"), context.get_context("
               Current context loaded:
                  device target: CPU
[3]: import os
                from itertools import chain
                import numpy as np
```

#### ②预处理数据集:

调用 convert\_to\_mindrecord 函数执行数据集预处理。在该函数中,将数据集格式转换为 MindRecord 格式,便于 MindSpore 读取。

开始出现各种问题:

问题 1: 未定义 args。

解决方法:该问题出现是因为我直接在 conda 终端上,运行 python 代码,将代码分割运行。args 继承的是第一段代码中的定义,而我单独运行第二段,因此查找不到。将其放到 jupyter lab 中,依次运行即可,或者在第二段代码中加入 import \*.py。

问题 2: 找不到对象 parse

```
convert_to_mindrecord(embed_size, aclimdb_path, preprocess_path, glove_path):
    """ convert imdb dataset to mindrecoed dataset """
parser = ImdbParser(aclimdb_path, glove_path, embed_size)
    parser.parse()
    if not os.path.exists(preprocess_path):
        print(f"preprocess path {preprocess_path} is not exist")
         os.makedirs(preprocess_path)
    train_features, train_labels, train_weight_np = parser.get_datas('train')
    \_convert\_to\_mindrecord(preprocess\_path,\ train\_features,\ train\_labels,\ train\_weight\_np)
    test_features, test_labels, _ = parser.get_datas('test')
    _convert_to_mindrecord(preprocess_path, test_features, test_labels, training=False)
    os.system("rm -f ./preprocess/aclImdb* weight*")
print("======= Starting Data Pre-processing ======="")
    convert_to_mindrecord(cfg.embed_size, args.aclimdb_path, args.preprocess_path, args.glove_path)
    print("========"Successful ========"")
 ----- Starting Data Pre-processing
                                            Traceback (most recent call last)
Input In [3], in <cell line: 175>()

176 os.system("rm -f ./preprocess/aclImdb* weight*")
Input In [3], in convert_to_mindrecord(embed_size, aclimdb_path, preprocess_path, glove_path)
161 """ convert imdb dataset to mindrecoed dataset """
    162 parser = ImdbParser(aclimdb_path, glove_path, embed_size)
 --> 163 parser.parse()
165 if not os.path.exists(preprocess_path):
                           ecess path {preprocess_path} is not exist")
AttributeError: 'ImdbParser' object has no attribute 'parse'
```

解决方法:该问题的出现是因为 parse 函数在前面已经定义过了,但是我错误的将其缩进到第一个类中,导致后面无法调用。

# 问题 3: 无效的 utf8 字符

```
**Starting Data Pre-processing ***

**Starting Data Pre-processing ***

**Starting Data Pre-processing ***

**Instance Processing ***

**Instance Pre-processing ***

**Instanc
```

解决方法:我一开始认为这是默认编码环境导致的问题,后面经查询验证发现是文件地址中含有中文。经更改后得以解决。

## 结果:

# 此时文件夹下生成预处理文件 preprocess:

名称	修改日期	类型
aclimdb_test.mindrecord0	2022/5/27 16:39	MINDRECORD0
aclImdb_test.mindrecord0.db	2022/5/27 16:39	Data Base File
aclImdb_test.mindrecord1	2022/5/27 16:39	MINDRECORD1
aclImdb_test.mindrecord1.db	2022/5/27 16:39	Data Base File
aclImdb_test.mindrecord2	2022/5/27 16:39	MINDRECORD2
aclImdb_test.mindrecord2.db	2022/5/27 16:39	Data Base File
aclimdb_test.mindrecord3	2022/5/27 16:39	MINDRECORD3
aclImdb_test.mindrecord3.db	2022/5/27 16:39	Data Base File
aclimdb_train.mindrecord0	2022/5/27 16:39	MINDRECORD0
aclImdb_train.mindrecord0.db	2022/5/27 16:39	Data Base File
aclImdb_train.mindrecord1	2022/5/27 16:39	MINDRECORD1
aclImdb_train.mindrecord1.db	2022/5/27 16:39	Data Base File
aclimdb_train.mindrecord2	2022/5/27 16:39	MINDRECORD2
aclImdb_train.mindrecord2.db	2022/5/27 16:39	Data Base File
aclImdb_train.mindrecord3	2022/5/27 16:39	MINDRECORD3
aclImdb_train.mindrecord3.db	2022/5/27 16:39	Data Base File
weight.txt	2022/5/27 16:39	文本文档

## ③创建数据集并读取第一个 label 的数据列表:

创建数据集并读取第1个 batch 中的 label 数据列表,和第1个 batch 中第1个元素的 feature 数据。

经过测试,该步骤一般不会出现问题: 结果如下图所示:

## ④定义网络:

导入初始化网络所需模块,定义模块来实现我们需要的网络参数及网络状态。然后针对 CPU 场景,自定义单层 LSTM 小算子堆叠,来实现多层 LSTM 大算子功能。实例化 SentimentNet,创建网络,最后输出网络中加载的参数。

#### 出现问题: nn. LSTMCell 已检测

解决方法:按照报错提示,将 nn. LSTMCell 更改为 nn. LSTM 即可。

## 网络定义结果:

OrderedDict([('embedding.embedding\_table', Parameter (name=embedding.embedding\_table, shape=(252193, 300), dtype=Float32, requires\_grad=False)), ('encoder.weight0', Parameter (name=encoder.weight0, shape=(320800, 1, 1), dtype=Float32, requires\_grad=True)), ('encoder.weight1', Parameter (name=encoder.weight1, shape=(240800, 1, 1), dtype=Float32, requires\_grad=True)), ('decoder.weight', Parameter (name=decoder.weight, shape=(2, 400), dtype=Float32, requires\_grad=True)), ('decoder.bias', Parameter (name=decoder.bias, shape=(2,), dtype=Float32, requires\_grad=True))])

#### ⑤加载训练集并保存模型:

加载训练数据集并配置好 checkpoint 信息。然后使用 model. train 接口,进行模型训练。这个阶段耗时较长,我是利用 CPU 跑的,速度大概在 4.1GHz 左右,每一步的时长却高达2500ms。总运行时长 4 个小时。

遇到问题: weight\_ih\_10 已存在。

解决方法:该文件我无法定位在哪里,可能是某个代码中定义的变量。因为是mindspore中的问题,我又重新安装了一遍 mindspore,重开了一个新的文件夹继续跑,发现可以解决这个问题。

## 训练集训练结果:

```
epoch: 1 step: 78, loss is 0.6957096
epoch: 1 step: 156, loss is 0.6743079
epoch: 1 step: 234, loss is 0.6446719
epoch: 1 step: 312, loss is 0.65861005
epoch: 1 step: 390, loss is 0.69689345
epoch time: 1215301.586 ms, per step time: 3116.158 ms
epoch: 2 step: 78, loss is 0.70962024
epoch: 2 step: 156, loss is 0.6102886
epoch: 2 step: 234, loss is 0.6964881
epoch: 2 step: 312, loss is 0.65087044
epoch: 2 step: 390, loss is 0.66379094
epoch time: 1041371.743 ms, per step time: 2670.184 ms
epoch: 3 step: 78, loss is 0.62043875
```

## ⑥模型验证:

创建并加载验证数据集(ds\_eval),加载由训练保存的CheckPoint文件,进行验证,查看模型质量。

最终验证得,对文本的情感分析正确率大概在85%左右,基本达到理想的成果。

# 四、 结果展示:

```
return self._executor(args_list, phase)
 KeyboardInterrupt
PS D:\NLP\1ab3\RNN> python .\1ab03.py
 Current context loaded:
          device target: CPU
  The feature of the first item in the first batch is below OrderedDict([('embedding.embedding_table', Parameter (name=embedding.embedding_table, shape=(252193, 300), dtype=Float32, requires_grad=False)), ('encoder.weight0', Parameter (name=encoder.weight0, shape=(320800, 1, 1), dtype=Float32, requires_grad=True)), ('encoder.weight1', Parameter (name=encoder.weight1, shape=(240800, 1, 1), dtype=Float32, requires_grad=True)), ('decoder.weight', Parameter (name=decoder.weight, shape=(2, 400), dtype=Float32, requires_grad=True)), ('decoder.weight, shape=(2, 400), dtype=Float32, requires_grad=True)), ('decoder.weight, shape=(2, 400), dtype=Float32, requires_grad=True))]
 epoch: 6 step: 390, loss is 0.2953758
 epoch time: 983130.995 ms, per step time: 2520.849 ms
 epoch: 7 step: 78, loss is 0.4075886

epoch: 7 step: 156, loss is 0.2930706

epoch: 7 step: 234, loss is 0.3777066

epoch: 7 step: 312, loss is 0.3998994

epoch: 7 step: 390, loss is 0.345225

epoch time: 8633244.550 ms, per step time: 22136.524 ms
 epoch: 8 step: 78, loss is 0.38182682
 epoch: 8 step: 156, loss is 0.4456376
epoch: 8 step: 234, loss is 0.291192
epoch: 8 step: 312, loss is 0.30604628
epoch: 8 step: 390, loss is 0.27665028
epoch time: 971882.619 ms, per step time: 2492.007 ms
epoch: 9 step: 78, loss is 0.33856133
epoch: 9 step: 156, loss is 0.27251458
epoch: 9 step: 234, loss is 0.3823075
epoch: 9 step: 312, loss is 0.265261
epoch: 9 step: 390, loss is 0.29062575
epoch time: 968556.788 ms, per step time: 2483.479 ms
epoch: 10 step: 78, loss is 0.28647646
epoch: 10 step: 156, loss is 0.25654155
epoch: 10 step: 234, loss is 0.31627426
epoch: 10 step: 312, loss is 0.28853276
epoch: 10 step: 390, loss is 0.27155113
epoch time: 952513.996 ms, per step time: 2442.344 ms
 epoch: 8 step: 234, loss is 0.291192
 epoch time: 952513.996 ms, per step time: 2442.344 ms
                  ======= Training Success =========
                                        = Starting Testing ========
= {'acc': 0.8562501282051282}
```

理解了 LSTM f	′利用 m 内 Sent:	验过程。 indspo	re 进行 et 网络	「自然说 ·进行模	吾言处: 集型训练	理应用 东及验	上的体:证正确	·验, 自率。	并且理 自己表	里解了; 边手解	如何通	过定义	和初	我进一步 始化基于 了进一步